

Policy-Guided Model Predictive Path Integral for Safe Manipulator Trajectory Planning with Constrained Discounted Reinforcement Learning

Abstract: 针对复杂动态环境下机械臂安全轨迹规划存在的硬约束执行难、环境泛化能力弱、规划实时性不足等问题,提出一种策略引导的模型预测路径积分(PG-MPPI)混合规划框架。该框架融合强化学习与模型预测控制优势,构建全局先验引导,局部实时优化和硬约束安全保障的闭环控制体系:设计约束折扣化 SAC(CD-SAC)离线学习策略,融入配置空间距离场安全引导项实现避障行为学习;以离线策略引导 MPPI 在线采样优化,提升采样效率与规划质量;引入 CBF 安全滤波器对控制指令实时修正,严格满足硬约束。以 SIASUN T12B 六关节机械臂为对象,在多障碍物场景开展仿真对比实验,结果表明,PG-MPPI 算法的无碰撞目标到达成功率优于对比算法,且能严格约束关节运动参数,保证轨迹平滑性与物理可行性,对动态环境与模型误差具备良好自适应能力,为机械臂自主安全作业提供了高效解决方案。

Keyword:

1 引言

随着工业自动化向柔性制造和人机协作方向发展,机械臂需要在高度非结构化且动态变化的环境中执行任务^[1]。这就要求运动规划算法不仅要具备实时避障能力,还需在满足复杂的运动学与动力学约束的同时,保证轨迹的平滑性与时间最优性^[2]。传统的基于采样的方法如 RRT*、PRM,虽然能保证概率完备性,但在高维空间中搜索效率低下,难以满足毫秒级的在线重规划需求^[3];基于优化的方法,如 CHOMP、TrajOpt,虽然轨迹质量较高,但极易陷入局部极小值,且对非凸障碍物的处理能力有限^[4]。

模型预测控制(Model Predictive Control, MPC)因其处理多变量约束和滚动优化的能力,成为解决这一问题的有力工具^[5]。特别是基于采样的模型预测路径积分控制(Model Predictive Path Integral, MPPI),利用图形处理单元(GPU)的大规模并行计算能力,通过在控制序列上施加随机扰动并加权平均,能够有效处理非光滑、非凸的代价函数^[6]。相比于基于梯度的 MPC,MPPI 不受代价函数可导性的限制,具有更强的鲁棒性^[7]。然而,标准 MPPI 的性能高度依赖于名义控制序列(Nominal Control Sequence)的质量和采样分布的覆盖范围。在面对长时域规划或环境中的复杂几何陷阱,如“U 形”障碍物或窄通道时,简单的均值初始化往往导致采样效率极低,容易收敛于次优甚至无法找到可行解^[8]。此外,如何在保证采样多样性的同时严格满足硬性安全约束,仍是 MPPI 面临的一大挑战^[9]。

深度强化学习通过离线训练,能够学习到具备全局视野的策略(Policy)和价值函数(Value Function),推理速度极快^[10]。然而,纯端到端的 RL 策略往往缺乏对环境变化的适应性,且难以提供硬性的安全保证^[11]。为了结合规划算法的精度与学习算法的速度,近期研究开始探索 RL 与 MPC 的融合架构。一种主流思路是

将学习到的策略作为 MPC 的热启动(Warm Start), 引导搜索过程^{[12][13]}。例如, TD-MPC^[14]潜在空间中结合了模型学习与规划; RL-Driven MPPI^[8]则直接利用离线策略生成的轨迹作为 MPPI 的均值, 显著提升了在线规划的收敛速度。尽管如此, 现有的混合方法在处理高维机械臂的配置空间安全(Configuration-space Safety)时, 往往仍采用简化的有符号距离(Signed Distance Function, SDF)^[15]或稀疏的碰撞惩罚, 忽略了关节空间拓扑结构的复杂性。

在安全约束处理方面, 控制屏障函数(Control Barrier Functions, CBF)提供了一种理论上严谨的安全保障机制^{[16][17]}。通过将安全集定义为状态空间的不变集, CBF 可以作为滤波器修正标称控制律。然而, CBF 的构造往往依赖于精确的模型和梯度, 且在高维非凸障碍物环境下的设计极具挑战。针对几何避障, 配置空间距离场(Configuration-space Distance Field, CDF)相比于传统的工作空间 SDF, 能直接反映机械臂整体构型与障碍物的接近程度^{[18][19]}。将 CDF 引入 RL 的奖励塑形或 MPC 的代价函数中, 可以提供更加平滑且具有全局导向性的安全梯度^[19]。此外, 为了解决软约束带来的震荡问题, 约束折扣(Constraint Discounting, CD)机制被提出^[20], 通过动态调整未来回报的折扣因子来实现软终止, 在安全学习方面表现出优越的稳定性。

基于上述背景, 本文提出一种策略引导的模型预测路径积分控制框架(Policy-Guided MPPI, PG-MPPI), 旨在解决高维机械臂在复杂动态环境下的安全运动规划问题。本文的主要贡献如下:

(1) 提出基于 CDF 的稠密安全引导策略学习方法: 突破传统工作空间有符号距离函数稀疏碰撞惩罚的局限, 将 CDF 融入 SAC 奖励函数设计, 利用其连续可微的梯度特性为避障行为提供全局稠密引导; 并结合时序差分约束折扣(TD-CD)技术, 将多类硬约束内化为策略分布倾向, 实现任务完成与安全避障的协同优化, 解决了纯强化学习避障学习效率低、约束处理易震荡的问题。

(2) 设计策略引导的 MPPI 在线规划架构, 实现全局先验与局部优化的深度融合: 将离线训练的约束折扣化 SAC (CD-SAC) 策略作为 MPPI 的名义控制序列生成器, 为其提供高质量热启动, 使采样分布集中于全局最优解附近, 解决了传统 MPPI 名义序列初始化差、高维空间采样效率低、易陷入局部极小值的痛点; 同时依托 MPPI 的在线滚动优化能力, 对离线策略的泛化误差进行实时修正, 兼顾规划的全局最优性与局部适应性。

(3) 构建 “策略软引导 + 优化硬约束 + 滤波器终保障” 的多层级安全体系: 在离线学习层通过 CDF 与 TD-CD 实现安全偏好的策略内化, 在线规划层通过 MPPI 的显式代价惩罚强化轨迹可行性, 执行层引入基于一阶 CBF 的安全滤波器, 对控制指令进行实时投影修正, 从理论层面保证避障、状态与控制三类硬约束的严格满足, 形成全流程的安全保障闭环, 解决了现有融合算法安全约束处理不严谨、极端场景易失效的问题。

本文的其余部分组织结构如下: 第二节为问题陈述与相关预备知识, 明确机械臂安全轨迹规划的数学模型及 MPPI、SAC 的基础原理; 第三节详细阐述所提 PG-MPPI 算法的实现细节, 包括离线约束折扣化强化学习策略与在线规划体系

的设计；第四节通过多场景仿真实验验证算法的有效性与优越性，并开展定量与定性对比分析；第五节对全文工作进行总结，同时展望后续研究方向。

2 Preliminaries

2.1 Problem Formulation

针对 n 自由度机械臂轨迹规划问题，定义 $q \in \mathbb{R}^n$ 表示机器人配置空间中一组关节角度，关节角度与速度共同构成系统状态向量 $x = [q, \dot{q}]$ ，关节加速度作为控制输入向量 u 。为适配离散化的在线规划与数值计算需求，将机械臂动力学系统建模为离散时间形式：

$$x_{t+1} = f(x_t, u_t) \quad (1)$$

其中， $f(\cdot)$ 为机械臂离散动力学映射函数， t 为离散时间步。

本研究的核心目标是在无限时域内寻求一系列控制输入，以最小化无限时域累积成本：

$$\min_{\{u_0, u_1, \dots\}} \sum_{t=0}^{\infty} \ell(x_t, u_t) \quad (2)$$

式中， $\ell(\cdot)$ 为过程成本函数。

为保障机械臂轨迹的安全性、物理可行性与运动平稳性，在上述最优控制目标基础上，进一步引入三类严格的核心约束，构成带约束的最优控制问题：

(1) 避障约束：定义机械臂连杆、关节与工作空间内障碍物间的最小安全距离 d_{safe} ，要求运动过程中实际最小距离 $d(x_t) \geq d_{\text{safe}}$ ，确保无几何碰撞；

(2) 状态约束：对关节角度和速度设置上下边界，即 $q_{\min} \leq q \leq q_{\max}$ ， $\dot{q}_{\min} \leq \dot{q} \leq \dot{q}_{\max}$ ，避免系统进入机械结构与驱动系统的物理不可行状态；

(3) 控制约束：对关节加速度 u 设置幅值上界，即 $\|u\| \leq u_{\max}$ ，匹配执行器实际输出能力，防止控制量突变引发机械振动、冲击或硬件损伤。

上述带约束的无限时域最优控制模型，构成了机械臂安全轨迹规划的基础数学框架，后续算法设计均围绕该模型的高效求解与约束严格满足展开。

2.2 Model Predictive Path Integral

MPPI 是一类基于采样的模型预测控制方法^[6]，其核心思想为在名义控制序列附近进行随机采样搜索，摒弃传统的最优单轨迹选择方式，通过指数权重对低成本采样轨迹进行加权聚合，使控制更新方向向优质轨迹集中，从而生成平滑且鲁棒的在线优化控制信号，适用于非线性、高维的动力学系统轨迹规划场景。

对于滚动时域 H 内的初始名义控制序列 $\bar{U} = \{\bar{u}_0, \dots, \bar{u}_H\}$ ，在时刻 t 对 K 条采样轨迹分别生成独立的零均值高斯噪声序列：

$$\varepsilon_i^k \sim N(0, \Sigma) \quad (3)$$

式中， $i = 0, \dots, H-1$ ， $k = 1, \dots, K$ ， Σ 为噪声协方差矩阵。以此构造第 k 条轨迹的候选控制量序列：

$$u_i^k = \bar{u}_i + \varepsilon_i^k \quad (4)$$

对每条候选控制序列执行前向仿真(rollout), 结合机械臂离散动力学模型得到对应的状态轨迹 $\{x_{t+i}^k\}_{i=0}^H$, 滚动时域上的累计成本为:

$$S_k = S(U^k; x_t^k) = \sum_{i=0}^{H-1} \ell(x_{t+i}^k, u_{t+i}^k) + \ell_f(x_{t+H}^k) \quad (5)$$

式中, $U = \{u_t, \dots, u_{t+H-1}\}$ 为控制序列, $\ell(\cdot)$ 为过程成本函数, $\ell_f(\cdot)$ 为终端成本函数。为突出低成本轨迹的引导作用, 对各采样轨迹的累积成本进行指数变换, 构建指数型权重:

$$\omega_k = \exp\left(-\frac{1}{\lambda}(S_k - S_{\min})\right) \quad (6)$$

式中, $\lambda > 0$ 为温度参数, 其值越小, 权重对低成本轨迹的偏向性越强, 反之则提升采样的探索性。使用归一化权重 $\tilde{\omega}_k$ 对所有采样噪声序列进行加权平均, 实现对初始名义控制序列的更新:

$$\bar{u}_i \leftarrow u_i + \sum_{k=1}^K \tilde{\omega}_k \varepsilon_i^k \quad (7)$$

MPPI 采用滚动时域执行策略, 仅提取更新后名义控制序列的初始时刻控制信号 $u_t^* = \bar{u}_0$ 作用于机械臂执行器, 驱动机器人完成当前时间步的运动。在进入下一时刻 $t+1$ 时, 需对控制序列执行滚动操作。

2.3 Soft Actor-Critic

强化学习核心目标为学习一个近似最优策略 π , 使智能体在与环境的交互过程中最大化长期期望回报。SAC 是基于最大熵强化学习框架的离线策略 Actor-Critic 算法^[21], 同时最大化期望累积回报与策略熵, 在保证策略优化的同时维持策略的探索性, 有效提升训练过程的稳定性与收敛速度, 避免策略陷入局部最优, 形式为:

$$\max_{\pi} \mathbb{E}_{\tau \sim \pi} \left[\sum_{t=0}^{\infty} \gamma^t \left(r(s_t, a_t) + \alpha \mathcal{H}(\pi(\cdot | s_t)) \right) \right], \quad (8)$$

其中 $\gamma \in [0, 1]$ 为折扣因子, $r(s_t, a_t)$ 为智能体在状态 s_t 执行动作 a_t 获得的即时回报, 熵 $\mathcal{H}(\pi(\cdot | s_t)) = -\mathbb{E}_{a \sim \pi(\cdot | s_t)} [\log \pi(a | s_t)]$ 越大策略的探索性越强, 反之则策略更偏向利用已有经验, $\alpha > 0$ 为温度参数。

SAC 采用双 Q 网络 $Q_{\theta_1}(s, a)$, $Q_{\theta_2}(s, a)$ 逼近状态动作值函数, 以缓解 Q 网络存在的值过估计问题。对于经验回放池 (Replay Buffer) $\mathcal{D}$ 中的样本 $(s_t, a_t, r_t, s_{t+1}, d_t)$ (d_t 为终止标志), 软 Bellman 备份目标为:

$$y_t = r_t + \gamma(1 - d_t) \mathbb{E}_{a_{t+1} \sim \pi_{\phi}(\cdot | s_{t+1})} \left[\min_{i \in \{1, 2\}} Q_{\bar{\theta}_i}(s_{t+1}, a_{t+1}) - \alpha \log \pi_{\phi}(a_{t+1} | s_{t+1}) \right] \quad (9)$$

其中, ϕ 为演员网络的可学习参数。

评论家网络的训练目标为最小化时序差分(TD)误差的均方误差, 即:

$$\min_{\theta_i} \mathbb{E}_{(s_t, a_t, r_t, s_{t+1}, d_t) \sim \mathcal{D}} \left[\left(Q_{\theta_i}(s_t, a_t) - y_t \right)^2 \right], \quad (10)$$

其中， θ_i 为 target critic 参数，通过随机采样实现离线策略学习。

演员网络采用随机策略形式，输出在状态 s 下各动作的概率分布，核心训练目标为最大化期望软值函数，即让策略输出的动作尽可能对应更高的状态动作值，同时保留一定的探索性，策略更新的目标函数为：

$$\min_{\phi} \mathbb{E}_{s_t \sim \mathcal{D}, a_t \sim \pi_{\phi}} \left[\alpha \log \pi_{\phi}(a_t | s_t) - \min_{i \in \{1, 2\}} Q_{\theta_i}(s_t, a_t) \right]. \quad (11)$$

温度参数 α 的取值直接影响策略的探索-利用平衡，SAC 中通常采用自调整机制优化 α ，将其作为可学习参数，通过最大化熵的期望回报目标更新。基于上述原理，SAC 采用神经网络学习得到最优策略 π_{ϕ}^* ，使其满足目标函数(8)的最大化条件。

3 Policy-Guided MPPI 轨迹规划

如第二节所讨论的，强化学习 RL 通过利用与环境的交互中收集的样本离线求解(8)来学习参数化策略。所学习的 RL 策略在在线决策过程中具有出色的实时性能，但由于训练过程中的次优性和罕见访问，可能在某些状态下失效。相比之下，MPPI 通过利用从当前状态开始的滚动来求解(5)，在每个时间步找到最优控制序列。它在确保所有可行状态下的策略可行性方面优于 RL 策略，但会导致较差的在线决策效率。在本节中，我们提出一种 RL 与 MPPI 结合的方法，从而为具有灵活成本标准的复杂系统提供更好的控制和实时性能。

3.1 算法框架

本文提出的 PG-MPPI (Policy-Guided MPPI) 算法框架，融合强化学习的全局策略引导能力与 MPPI 的局部在线精细优化能力，实现复杂环境下机械臂全局和局部协同的安全轨迹规划，整体形成全局先验指导，局部实时优化和安全硬约束保障的闭环控制，算法架构如图 1 所示。




Figure 1 PG-MPPI 架构图

该框架核心分为离线学习阶段和在线规划阶段两大模块：

(1) 离线阶段(Offline learning)，用强化学习在仿真环境中反复交互得到一个先验控制器。把“到达目标 + 安全约束”编码进奖励或约束折扣里，训练得到策

略 $\pi_\phi(a|s)$ 。这样的策略能提供长视野的动作建议，并把大量计算从在线时刻前移到离线训练中。

(2)在线阶段(Online planning)，在当前真实状态与环境下实时优化并保证安全执行。将离线策略输出作为 MPPI 的名义控制序列，在其附近采样滚动并计算轨迹代价，经路径积分权重加权后提取控制序列首步作为当前动作；再通过安全滤波器修正期望控制，使其满足安全约束。这样既利用 RL 先验提升采样效率，又用 MPPI 的显式代价与滚动优化对分布外变化进行纠偏与稳健化。

3.2 离线策略学习

以机械臂末端精准到达指定目标位置作为核心主任务，同时以 CDF 作为核心安全引导项，将其梯度信息与安全惩罚机制融入强化学习的奖励函数设计中，引导策略在离线训练过程中主动学习避障行为，使机械臂能够自主远离障碍物碰撞区域，实现任务完成与安全避障的协同优化。

3.2.1 奖励设计

令机械臂末端 $x(q_t)$ 与目标位置 x_g 的欧氏距离为：

$$d_t = \|x(q_t) - x_g\|_2 \quad (12)$$

基于该距离设计进度型目标奖励，使奖励信号随末端向目标靠近呈连续变化，为策略优化提供稳定的梯度引导，形式为：

$$r_{\text{goal}}(t) = k_g (d_{t-1} - d_t) \quad (13)$$

其中， k_g 为奖励权重，用于调节主任务在奖励函数中的占比。

传统障碍物建模常采用 SDF 函数 f_s 表示空间一点 p 与机器人表面 $\partial r(q)$ 之间的距离：

$$f_s(p, q) = \pm \min_{p' \in \partial r(q)} \|p - p'\| \quad (14)$$

式中， $\pm$ 为表示距离方向的符号，如果 p 在机器人外部则为正，在内部则为负。此类模型仅将碰撞作为硬约束或简单软惩罚，在检测到碰撞时增大成本，未充分利用障碍物的距离信息为无碰撞路径规划提供主动引导，存在避障策略学习效率低的问题。

为解决上述问题，本研究采用 CDF 函数 f_c 进行障碍物建模^[19]，该函数以关节值 q 为自变量表示机械臂当前关节配置到发生碰撞的临界关节配置的最小距离，这一距离将确立机器人与该点之间的接触：

$$f_c(p, q) = \min_{q'} \|q - q'\| \quad (15)$$

式中， q' 满足约束 $f_s(p, q') = 0$ ，可以在 SDF 模型的零水平集上通过逆运动学找到给定一点 p 对应的配置集 q' 。

CDF 函数在配置空间内几乎处处连续可微，其梯度天然指向局部最优的碰撞逃离方向，能够为避障行为学习提供直接的梯度引导信号，是适配机械臂关节空间轨迹规划的安全引导项，原理如图 2 所示。




Figure 2 基于 CDF 的 2-DOF 轨迹示意图. (a) 配置空间 CDF 等值线与轨迹, 黑色等值线为 $f_c(q_t) = 0$, 对应与障碍物接触的配置集合. 沿等值线切线与梯度运动会绕开障碍物. (b) 配置空间轨迹对应的工作空间轨迹.

基于 CDF 函数设计非线性安全惩罚项实现对碰撞风险的自适应惩罚, 形式为:

$$r_{\text{safe}}(t) = -\mu \left[\max(0, d_m - f_c(q_t)) \right]^p \quad (16)$$

式中, $\mu > 0$ 为安全惩罚权重, $p \geq 1$ 为惩罚幂次, $d_m > 0$ 为安全裕度阈值. 当机械臂关节配置处于安全区域 $f_c(q_t) \geq d_m$ 时, 安全惩罚项为 0, 不干扰主任务执行; 当关节配置进入低 CDF 风险区域 $f_c(q_t) < d_m$ 时, 惩罚值随 CDF 值的减小呈非线性增长, 且惩罚幂次越大, 碰撞风险区域的惩罚强度越高, 能够快速将策略推回安全区域, 同时避免轻微越界时的过度惩罚, 兼顾避障安全性与策略探索性.

为进一步强化安全约束, 当机械臂发生实际碰撞 $f_c(q_t) \leq 0$ 时, 立即终止当前训练回合(episode), 并叠加一次性惩罚 $r_{\text{col}}(t)$. 综合目标奖励、安全惩罚项与碰撞一次性惩罚, 得到总奖励函数为:

$$r_t = r_{\text{goal}}(t) + r_{\text{safe}}(t) + r_{\text{col}}(t) \quad (17)$$

该奖励函数实现了主任务目标与安全避障约束的有机融合, 既通过进度型奖励驱动机械臂完成末端定位任务, 又借助 CDF 的梯度引导与非线性惩罚机制, 让策略在离线训练中主动学习避障行为, 从奖励设计层面保障机械臂轨迹的任务可行性与安全无碰撞性.

3.2.2 基于折扣因子的约束

为实现机械臂轨迹规划中多类约束的统一化、自适应管理, 本节首先构建约束通用表达形式, 再通过随机终止信号将约束违规程度转化为奖励折扣权重, 最后结合指数移动平均(EMA)与有限时域折扣规则, 形成兼顾安全性与控制连续性的约束处理方案.

将机械臂运动过程中的各类物理约束与安全约束统一抽象为不等式约束通用形式, 覆盖关节位置边界、关节速度和加速度幅值等所有硬约束要求:

$$c_i(x, u) \leq 0 \quad \forall i \in \mathcal{I}, \quad (18)$$

为避免手工设计惩罚函数存在的阈值依赖、违规叠加风险，本节采用基于约束违规的随机终止信号，直接将违规程度映射为对未来奖励的折扣权重，定义为：

$$\delta_t = \max_{i \in \mathcal{I}} \left(p_i^{\max} \cdot \text{clip} \left(\frac{[c_t]_i}{c_i^{\max}}, 0, 1 \right) \right) \quad (19)$$

式中，超参数 $p_i^{\max} \in [0, 1]$ 为约束 i 的最大终止概率超参数， $[c_t]_i$ 为第 t 步中约束 i 的实际违规量， $c_i^{\max}$ 是所有轨迹中第 i 个约束的最大违反值。公式(19)具有如下性质：

(1) 约束违规不再依赖手工设计的惩罚函数，而是直接将违规程度转化为对未来奖励的折扣权重，违规越严重， δ_t 越接近 $p_i^{\max}$ ，未来奖励被折扣的比例越高，引导机器人主动规避违规。

(2) 只要有一项约束严重违规，就会触发较高的 δ_t ，避免多项轻微违规叠加导致安全风险或运动失效，确保约束的严格性。

(3) 无违规时， $[c_t]_i = 0$ ， $\delta_t = 0$ ，未来奖励无折扣，鼓励正常探索；轻微违规时， $0 < [c_t]_i < c_i^{\max}$ ， $\delta_t \in (0, p_i^{\max})$ ，未来奖励部分折扣，既警示违规又允许机器人学习恢复策略；严重违规时， $[c_t]_i \geq c_i^{\max}$ ， $\delta_t = p_i^{\max}$ ，直接终止未来所有奖励，严格禁止严重违规。

为避免单一批次训练中极端违规值导致的折扣因子波动，同时实现违规参考范围的数据驱动自适应学习， $c_i^{\max}$ 采用指数移动平均 (EMA) 机制更新各约束的历史最大违规值 $c_i^{\max}$ ：

$$c_i^{\max} \leftarrow \tau_c \cdot \hat{c}_i^{\max} + (1 - \tau_c) \cdot c_i^{\max} \quad (20)$$

式中， $\hat{c}_i^{\max} = \max_t [c_t]_i$ 是当前训练批次中所有时刻 t 第 i 个约束的最大违反值， $\tau_c \in [0, 1]$ 是衰减率超参数，表示保留历史信息的百分率。该机制使违规参考值随训练过程动态调整，初期快速适配环境约束的实际范围，后期趋于稳定，保证折扣因子的合理性与策略学习的收敛性。

3.3.3 学习策略(CD-SAC: Constraint-Discounted SAC)

基于上述约束折扣机制，结合 SAC 算法的最大熵强化学习框架，采用约束折扣化的 SAC(CD-SAC)学习策略，将约束信息以软终止形式注入 SAC 的时序差分备份过程，实现“主任务奖励+安全引导+约束折扣”的多目标融合学习。

Agent 在受约束动力学环境中滚动采样转移 (s_t, u_t, r_t, s_{t+1}) ，并将每一步的约束违反程度根据(19)映射为一个软终止强度 δ_t ，进而得到时变折扣因子 γ_t ：

$$\gamma_t = \gamma (1 - \text{clip}(\delta_t, 0, 1)) \quad (21)$$

式中， γ 为 SAC 基准折扣。当发生约束违背或接近违背时， γ_t 减小，从而削弱未来回报跨越不安全转移的传播，达到软终止的效果。

在 critic 更新中，保持 SAC 的双 Q 网络与熵正则形式不变，仅将 TD 目标中

的常数折扣替换为 γ_t 。对从回放池采样的 mini batch $\{(s_t, u_t, r_t, s_{t+1}, \gamma_t)\}$ ，先构造 soft 值函数目标：

$$V(s_{t+1}) = \mathbb{E}_{a_{t+1} \sim \pi(\cdot|s_{t+1})} \left[\min(Q_{\bar{\theta}_1}(s_{t+1}, a), Q_{\bar{\theta}_2}(s_{t+1}, a)) - \alpha \log \pi(a|s_{t+1}) \right] \quad (22)$$

则 TD-CD 目标为：

$$y_t = r_t + \gamma_t V(s_{t+1}) \quad (23)$$

Critic、Actor 与温度参数 α 的更新保持 SAC 标准形式不变，整体训练流程仍为在线交互式的 off-policy 学习，区别在于回放池额外存储每条转移的 γ_t ，从而在 critic 的 TD 备份中注入约束信息。

与奖励硬惩罚约束相比，TD-CD 将约束作用于价值传播路径：约束违背或程度加剧时会自动减小折扣因子，衰减后续未来回报对当前状态-动作价值的影响，降低策略对不安全区域的价值高估与梯度放大；该机制无需依赖 on-policy 轨迹，天然兼容经验回放池，让训练更平滑稳定，也可解释为软终止下的安全引导。

3.3 在线轨迹规划

离线训练的 CD-SAC 策略可为机械臂规划提供全局长视野动作指导，能规避训练场景中的静态障碍物，但对未建模动态障碍、模型误差及外部扰动的局部适配能力不足。为此，本文将该离线策略与 MPPI 的局部在线优化能力融合，并引入 CBF 安全滤波器，既保留全局策略优势，又通过 MPPI 适配实时环境变化，最终经安全滤波器严格满足所有硬约束，实现复杂动态环境下机械臂的安全高效轨迹规划。

3.3.1 基于 CBF 的安全滤波器

安全滤波器是在线规划阶段的最后一道安全屏障，核心作用是对 MPPI 输出的期望控制指令进行实时修正，确保最终作用于机械臂的控制量严格满足避障、状态与控制硬约束，从理论层面保证系统的安全性。

本研究以一阶控制障碍函数(CBF)为核心^[6]，在速度层设计安全滤波器，实现对碰撞风险的实时规避与控制量的可行化投影。定义机器人配置 q 时， $p_i(q)$ 为连杆 i 的端点，为量化机械臂与障碍物的安全间隙，最小间隙函数为：

$$c(q) = \min_j \min_{i \in \{0, \dots, n-1\}} \left(\text{dist}(o_j, [p_i(q), p_{i+1}(q)]) - \tilde{r}_j \right) \quad (24)$$

式中， $\text{dist}(o, [a, b])$ 为点 o 到线段 $[a, b]$ 的欧氏距离， $\tilde{r}_j$ 为预设的最小安全距离。因此，当 $c(q) < 0$ 时机械臂与障碍物发生几何碰撞； $c(q) \geq 0$ 时，机械臂处于安全区域，且 $c(q)$ 的值越大，安全裕度越高。

将 $c(q)$ 作为安全函数，要求安全函数的时间导数满足非负约束，确保机械臂从安全状态出发时，始终向安全裕度增大的方向运动，避免进入碰撞区域：

$$\dot{c}(q) = \nabla c(q)^T \dot{q} \geq -\alpha(c(q)) \quad (25)$$

其中， $\alpha(\cdot)$ 为类 $\mathcal{K}$ 函数（本研究采用线性 $\alpha(c) = \rho c$ ， $\rho > 0$ ），其作用是对安全

函数的衰减速度进行约束，当 $c(q)$ 趋近于 0 时，强制 $\dot{c}(q) \geq 0$ ，使机械臂快速远离碰撞区域。

安全滤波器的本质是带线性不等式约束的二次规划(QP)问题^[22]，目标是在满足 CBF 约束与关节速度物理约束的前提下，找到与 MPPI 输出的期望关节速度 $\dot{q}_{\text{des}}$ 最接近的可行关节速度 $\dot{q}_{\text{safe}}$ 。构建的 QP 优化问题如下：

$$\begin{aligned} \dot{q}_{\text{safe}} &= \arg \min_{\dot{q}} \|\dot{q} - \dot{q}_{\text{des}}\| \\ \text{s.t. } \nabla c(q)^\top \dot{q} + \alpha(c(q)) &\geq 0 \end{aligned} \quad (26)$$

该 QP 问题存在闭式解，可通过拉格朗日法实现实时求解，满足在线轨迹规划的实时性需求。当 $\nabla c^\top \dot{q}_{\text{des}} \geq -\alpha(c)$ 时，约束不被激活，解为 $\dot{q}_{\text{safe}} = \dot{q}_{\text{des}}$ ；当约束激活时，将 $\dot{q}_{\text{des}}$ 正交投影到约束的半空间边界上，得到可行解：

$$\dot{q}_{\text{safe}} = \dot{q}_{\text{des}} - \frac{\alpha(c) + \nabla c(q)^\top \dot{q}_{\text{des}}}{\|\nabla c(q)\|_2^2 + \delta} \nabla c(q) \quad (27)$$

其中 $\delta > 0$ 为数值稳定项。

3.3.2 算法实现

Policy-Guided MPPI(PG-MPPI)把 MPPI 和学习到的策略(policy)结合起来，用于安全且高效的机械臂规划。整体实现步骤如表 1 所示。

Table 1 PG-MPPI Algorithm

Algorithm 1 PG-MPPI Pseudocode	
Require: Dynamics $x_{t+1} = f(x_t, u_t)$; horizon H ; samples K ; temperature λ ; noise covariance Σ ; stage cost $\ell(x, u)$; terminal cost $\ell_f(x)$; learned policy $\pi_\phi(a s)$; control constraint set $\mathcal{U}$; safety filter $\mathcal{F}_{\text{safe}}(\cdot)$.	
Ensure: u_t applied to the robot at each time step.	
1:	Initialize nominal control sequence $U = \{u_0, \dots, u_{H-1}\}$.
2:	for $t = 0, 1, 2, \dots, K$ do
3:	Observe current state x_t .
	Policy-guided nominal (warm start)
4:	Predict a nominal rollout under the learned policy:
5:	$\hat{x}_0 \leftarrow x_t$
6:	for $i = 0$ to $H - 1$ do
7:	$\hat{u}_i \leftarrow \mathbb{E}[\pi_\phi(\cdot \hat{x}_i)]$
8:	$\hat{x}_{i+1} \leftarrow f(\hat{x}_i, \hat{u}_i)$
9:	end for
10:	Set the nominal sequence $U \leftarrow \{\hat{u}_0, \dots, \hat{u}_{H-1}\}$.
	MPPI update
11:	$U \leftarrow \text{MPPI}(x_t, U; f, \ell, \ell_f, H, K, \lambda, \Sigma, \mathcal{U})$
	Safety filtering and execution
12:	$u_t^* \leftarrow u_0$
13:	$u_t^{\text{safe}} \leftarrow \mathcal{F}_{\text{safe}}(x_t, u_t^*)$
14:	Apply u_t^{safe} to the robot, obtain next state x_{t+1} .
	Receding horizon shift
15:	$U \leftarrow \{u_1, u_2, \dots, u_{H-1}, u_{H-1}\}$
16:	end for

离线阶段，通过仿真环境训练一个策略 $\pi_\phi(a | x)$ ，用基于 CDF 的安全项引导策略学会避障/远离碰撞区域。在线阶段，首先通过 CD-SAC 策略前向滚动生成滚动时域 H 内的名义控制序列，并将其设置为 MPPI 的初始名义控制序列；之后

根据 MPPI 标准更新算法, 执行采样-滚动-代价计算-加权更新流程, 得到优化后的控制序列; 提取优化后控制序列初始时刻控制量, 将其送入安全滤波器 $\mathcal{F}_{\text{safe}}(x_t, u_0)$, 得到满足所有硬约束的可行控制量; 最后, 将可行控制量作用于机械臂, 驱动机器人完成当前时间步的运动, 并更新控制序列。

相比于传统的纯模型预测控制或纯强化学习方法, PG-MPPI 融合了两者的优势, 具有以下显著特点:

(1)引导采样与方差缩减。标准 MPPI 的名义控制通常基于上一时刻的平移或简单的启发式, 容易陷入局部极小值或在复杂约束下失效。PG-MPPI 利用 RL 策略提供高质量的热启动序列, 将采样分布集中在全局更优的解附近, 极大地提高了采样的有效性和收敛速度, 降低了达到同等控制性能所需的样本数量。

(2)全局规划能力与局部快速修正。RL 策略通过离线训练学习到了长视角的价值函数, 能够处理需要全局信息的任务; 而 MPPI 则通过显式的代价函数和在线滚动优化, 能够对策略输出进行高频、实时的局部修正, 有效应对离线训练未见过的障碍物或模型误差。

(3)互补的安全与约束处理。基于 CDF 的 RL 训练使策略内化了软性的安全偏好(Tendency to be safe), 输出的初始轨迹即使不完美也往往位于安全区域附近; MPPI 在此基础上通过硬约束投影和碰撞代价惩罚, 进一步在执行层面保证了轨迹的可行性和安全性, 形成了“策略软引导 + 优化硬约束”的双重保障机制。

4 Experiments

为验证本文提出的 PG-MPPI 算法在机械臂安全轨迹规划中的有效性与优越性, 本节以 SIASUN T12B 六关节机械臂为实验对象, 基于 MuJoCo^[23]动力学仿真框架搭建实验平台, 并基于 CDF^[19]对环境障碍物进行建模, 设计多场景对比实验, 从策略训练收敛性、避障轨迹质量、多场景任务成功率、运动学约束满足性等维度, 将 PG-MPPI 与 SF-MPPI(带安全滤波器的标准 MPPI 算法)、SF-SAC(带安全滤波器的标准 CD-SAC 算法)进行定量与定性对比分析。所有实验均在搭载 Intel i7-14650HX 处理器、NVIDIA RTX 4050 显卡的工作站上完成, 仿真时间步长设为 0.01s。

4.1 策略学习

测试环境如图 3 所示, 运动目标的坐标为(0.6, 0.2, 0.3), 为图中绿色球体。工作空间中存在以(0.8, 0.0, 0.5)为中心的十字形障碍物, 由 13 个半径为 0.05 的球体构成, 如图中红色球体。




Figure 3 机器人与障碍物仿真

基于 4.1 节搭建的仿真环境与设计的约束折扣机制，采用所提 CD-SAC 算法对 Actor 网络与 Critic 网络进行离线训练，网络的核心超参数如表 2 所示。

Table 2 CD-SAC parameters

type	hyper-parameters	value	function
Constraint Discount	vel bound	1rad/s	关节速度约束
	acc bound	2rad ² /s	加速度约束
	$p^{\max}$	1	公式(19)终止概率
	τ_c	0.99	公式(20)衰减率
SAC Network	hide dim	256	actor/critic MLP 每层宽度，共两层
	learning rate	3e-4	Adam 学习率
	γ	0.99	公式(21)基础折扣
	batch size	256	每次 update 的 batch 大小
Environment Reward	action repeat	5	每个 RL step 内部执行 5 次物理步
	reach tol	0.03	成功判定阈值
	max ep steps	2500	每回合最大 step
	success bonus	10.0	成功时额外奖励并终止
	total steps	200000	总环境交互步数

训练过程的核心指标演化曲线如图 4 所示。在训练初期，由于策略尚未探索到有效动作空间，回合累积回报(Episode Return)处于低位且波动显著。随着训练迭代进行，策略性能呈现快速提升趋势：Episode Return 从显著负值区间迅速攀升，并在约 50,000 步时趋于收敛，表明策略已学习到以最小代价完成末端定位任务的控制模式。




Figure 4 训练过程指标曲线

从定量评估指标来看，末端与目标的平均距离(Eval Mean Distance)在初始阶段约为 0.35 m，随后呈指数级下降；在 50,000 步后稳定降至 0.02m 以下，持续满足任务的精度要求。与此同时，单回合平均执行步数(Eval Mean Steps，右轴)从接近最大限制值急剧下降至低位，这一同步变化清晰地证明，策略行为已从训练初期的“超时探索/目标不可及”模式，高效转变为“快速定位/提前成功终止”模式，验证了算法的快速收敛性与后期性能的稳定性的。

在安全性方面，碰撞率(Eval Collision Rate)在整个训练周期内始终维持在接近 0 的水平。相应地，任务成功率(Success)与无碰撞成功率(Success no-collision)在 50,000 步后同步达到 100% 并保持稳定。这一结果充分说明，得益于 3.2.1 节所提 CDF 安全引导机制，策略不仅能稳定完成主任务，更能在运动过程中自主规避障碍物，实现了任务性与安全性的深度统一。

此外，自动温度参数 α 的变化趋势反映了策略探索与利用的动态平衡：在收敛阶段经历短暂的探索强度回升后， α 逐步下降并稳定在 0.007 附近。这表明算法在训练后期主动降低了探索熵，锁定了最优的确定性控制策略，确保了输出轨迹的鲁棒性。

综上所述，实验结果验证了所提 CD-SAC 算法能够在较少的训练步数内实现高任务成功率与近零碰撞率，并在训练后期保持卓越的性能稳定性，充分兼顾了机械臂运动的效率、安全性与控制稳定性。

4.2 避障轨迹

基于离线训练收敛的 CD-SAC 策略网络，本文配置了 PG-MPPI 在线规划器的核心超参数，具体取值如表 3 所示。在实时执行阶段，算法采用双层时间尺度架构：离线学习得到的最优策略作为全局先验，以 0.1s 为周期进行滚动更新；而 MPPI 则在该先验引导下，以 0.01s 的高频周期执行采样与局部优化，生成最终的控制指令。

Table 3 PG-MPPI parameters

hyper-parameters	value	function
policy update	0.1s	策略更新周期
horizon	25	预测时间域长度
num samples	200	采样轨迹数
λ	0.6	温度参数
noise_std	0.6	采样标准方差

通过独立运行 SF-MPPI、SF-SAC 和 PG-MPPI 轨迹规划算法，获取了机器人末端的运动轨迹如图 5 所示，运行轨迹以黄色曲线标识呈现。SF-MPPI 通过安全滤波器实现了对局部障碍物的硬约束避碰，但其短视的优化特性使其在缺乏长时域引导时易陷入局部极小值，表现为轨迹在障碍物前发生非目标性终止，无法完成末端定位任务。反观 SF-SAC 与 PG-MPPI，二者均内化了训练环境的障碍物分布先验，能够规划出全局最优的避障路径。实验结果表明，这两种算法不仅能精准到达目标位置，且在整个运动过程中，机械臂所有连杆与障碍物之间始终保持安全距离，实现了零碰撞运行。




Figure 5 标准障碍物运行轨迹

PG-MPPI 算法的关节运动学响应曲线如图 6 所示。由图可见，在整个运动周期内，所有关节的速度与加速度均严格限制在预设的物理边界内，无任何越界行为；同时，速度轨迹呈现出连续且低波动的光滑特性，验证了所提算法在保证物

理可行性的同时，具备优异的运动平滑性。




Figure 6 PG-MPPI 各关节运动曲线

简化后的障碍物场景如图 7 所示，三类算法均实现了无碰撞的目标到达。SF-MPPI 因缺乏全局策略引导，仅能通过局部避障完成路径规划，导致轨迹与障碍物的安全间隙偏小；SF-SAC 与 PG-MPPI 则借助离线训练的全局规划先验，规划出具备充足安全裕度的避障轨迹，顺利抵达目标位置。




Figure 7 简化障碍物运行轨迹

在标准环境的基础上进行重布局形成如图 8 所示障碍物，SF-MPPI 与 SF-SAC 算法均暴露了其固有缺陷：SF-MPPI 受限于局部视野，其采样轨迹在障碍密集区易陷入死区，导致任务失败；SF-SAC 的离线策略因未见过此类分布，泛化失效引发轨迹碰撞。相比之下，PG-MPPI 通过“全局策略引导 + 局部在线优化”的协同机制，不仅利用先验知识避开了潜在的碰撞陷阱，更通过 MPPI 的实时迭代对未建模障碍做出自适应调整，从而生成一条无碰撞的可行轨迹并成功完成定位任务。




Figure 8 复杂障碍物运行轨迹

为量化验证算法的泛化能力与避障性能，本研究在标准障碍物仿真环境与复杂障碍物仿真环境中，分别随机生成 10 组典型的机械臂起始关节配置并开展测试。测试并统计三种算法的无碰撞到达目标成功率，结果如表 4 所示。在训练所采用的标准障碍物环境中，SF-SAC 与 PG-MPPI 算法的无碰撞成功率均达到 100%，二者表现持平；而在复杂障碍物环境下，PG-MPPI 算法凭借“全局策略引导 + 局部实时优化”的协同机制，仍保持 100% 的成功率，显著优于 SF-SAC 算法。上述结果充分证明，所提算法具备更优越的环境泛化能力与动态避障性能。

Table 4 典型起始配置成功率 (%)

Method	SF-MPPI	SF-SAC	PG-MPPI
Normal Obs	20	100	100
Complex Obs	20	60	100

上述实验中，基于 PG-MPPI 算法规划得到的部分轨迹结果如图 9 所示。由图可知，针对不同起始关节配置生成的多条轨迹，均能灵活适配环境中的障碍物分布，在保持充足安全裕度的同时平滑规划出无碰撞路径，精准抵达目标位置，充分体现了算法在不同初始条件下的轨迹规划鲁棒性与环境适应性。




Figure 9 基于 PG-MPPI 的运行轨迹

综合上述定性与定量实验分析可得，本文提出的 PG-MPPI 算法在实现全局

避障的同时完成动态局部避障，且能通过约束折扣机制与安全滤波的双重保障，对关节轨迹的速度和加速度实施硬约束，有效确保机械臂运动轨迹的平滑性与稳定性。

5 结论

本研究针对复杂动态环境下的机械臂运动规划问题，提出了一种融合全局策略引导与局部模型预测优化的 PG-MPPI 算法。该算法通过引入预训练的 SF-SAC 策略网络，为 MPPI 提供高质量的初始采样分布，有效解决了传统 MPPI 在高维空间中采样效率低下与易陷入局部最优的问题。实验结果表明，在标准障碍物环境中，所提算法与基线算法均能实现 100% 的无碰撞到达成功率；而在更具挑战性的复杂障碍物环境下，PG-MPPI 算法依然保持 100% 的成功率，显著优于 SF-SAC 算法。这充分验证了该算法在未见场景中卓越的泛化能力与鲁棒的避障性能。未来工作将进一步探索将该框架迁移至真实硬件平台，并结合环境感知模块，以实现未知动态障碍物的实时自适应规划。

参考文献

- [1] Liu J, Yap H J, Khairuddin A S M. Review on motion planning of robotic manipulator in dynamic environments[J]. *Journal of Sensors*, 2024, 2024(1): 5969512.
- [2] Koptev M, Figueroa N, Billard A. Reactive collision-free motion generation in joint space via dynamical systems and sampling-based MPC[J]. *The International Journal of Robotics Research*, 2024, 43(13): 2049-2069.
- [3] Luo S, Zhang M, Zhuang Y, et al. A survey of path planning of industrial robots based on rapidly exploring random trees[J]. *Frontiers in Neurorobotics*, 2023, 17: 1268447.
- [4] Schulman J, Ho J, Lee A X, et al. Finding locally optimal, collision-free trajectories with sequential convex optimization[C]//*Robotics: science and systems*. 2013, 9(1): 1-10.
- [5] Mayne D Q. Model predictive control: Recent developments and future promise[J]. *Automatica*, 2014, 50(12): 2967-2986.
- [6] Williams G, Drews P, Goldfain B, et al. Information-theoretic model predictive control: Theory and applications to autonomous driving[J]. *IEEE Transactions on Robotics*, 2018, 34(6): 1603-1622.
- [7] Belvedere T, Ziegltrum M, Turrisi G, et al. Feedback-MPPI: fast sampling-based MPC via rollout differentiation—adios low-level controllers[J]. *IEEE Robotics and Automation Letters*, 2025, 11(1): 1-8.
- [8] Qu Y, Chu H, Gao S, et al. RL-driven MPPI: Accelerating online control laws calculation with offline policy[J]. *IEEE Transactions on Intelligent Vehicles*, 2023, 9(2): 3605-3616.
- [9] Ezeji O, Ziegltrum M, Turrisi G, et al. BC-MPPI: A Probabilistic Constraint Layer for Safe Model-Predictive Path-Integral Control[C]//*Workshop on Agents and Robots for reliable Engineered Autonomy*. Cham: Springer Nature Switzerland, 2025: 131-143.
- [10] Tamizi M G, Yaghoubi M, Najjaran H. A review of recent trend in motion planning of industrial robots: MG Tamizi et al[J]. *International Journal of Intelligent Robotics and Applications*, 2023, 7(2): 253-274.

- [11] Stan L, Nicolescu A F, Pupăză C. Reinforcement learning for assembly robots: A review[J]. *Proceedings in Manufacturing Systems*, 2020, 15(3): 135-146.
- [12] Romero A, Aljalbout E, Song Y, et al. Actor–Critic Model Predictive Control: Differentiable Optimization Meets Reinforcement Learning for Agile Flight[J]. *IEEE Transactions on Robotics*, 2025, 42: 673-692.
- [13] Baltussen T, Orrico C A, Katriniok A, et al. Value Function Approximation for Nonlinear MPC: Learning a Terminal Cost Function with a Descent Property[C]//2025 IEEE 64th Conference on Decision and Control (CDC). IEEE, 2025: 5507-5514.
- [14] Hansen N, Wang X, Su H. Temporal difference learning for model predictive control[J]. *arXiv preprint arXiv:2203.04955*, 2022.
- [15] Liu P, Zhang Y, Wang H, et al. Real-time collision detection between general SDFs[J]. *Computer Aided Geometric Design*, 2024, 111: 102305.
- [16] Ames A D, Coogan S, Egerstedt M, et al. Control barrier functions: Theory and applications[C]//2019 18th European control conference (ECC). Ieee, 2019: 3420-3431.
- [17] Almubarak H, Sadegh N, Theodorou E A. Safety embedded control of nonlinear systems via barrier states[J]. *IEEE Control Systems Letters*, 2021, 6: 1328-1333.
- [18] Li Y, Miyazaki T, Kawashima K. One-Step Model Predictive Path Integral for Manipulator Motion Planning Using Configuration Space Distance Fields[J]. *arXiv preprint arXiv:2509.00836*, 2025.
- [19] Li Y, Chi X, Razmjoo A, et al. Configuration space distance fields for manipulation planning[J]. *arXiv preprint arXiv:2406.01137*, 2024.
- [20] Crestaz P N, De Matteis L, Chane-Sane E, et al. TD-CD-MPPI: Temporal-Difference Constraint-Discounted Model Predictive Path Integral Control[J]. *IEEE Robotics and Automation Letters*, 2025, 11(1): 498-505.
- [21] Haarnoja T, Zhou A, Abbeel P, et al. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor[C]//International conference on machine learning. Pmlr, 2018: 1861-1870.
- [22] Ames A D, Xu X, Grizzle J W, et al. Control barrier function based quadratic programs for safety critical systems[J]. *IEEE Transactions on Automatic Control*, 2016, 62(8): 3861-3876.
- [23] Todorov E. Convex and analytically-invertible dynamics with contacts and constraints: Theory and implementation in mujoco[C]//2014 IEEE International Conference on Robotics and Automation (ICRA). IEEE, 2014: 6054-6061.